

Best practices for developing microbiome-based disease diagnostic classifiers through machine learning

Published : Gut Microbes (2025.04.04) | Peikun Li, Min Li, Wei-Hua Chen

Disease Cohort

Samples

Disease : 5988
Healthy : 4411

Disease Groups

Intestinal : 7
Liver : 1
Metabolism : 3
Autoimmune : 4
Mental : 5



16s rRNA
WholeMetaGenome





Machine
Learning



Disease Classification

Figure 1

Workflow



Concepts [Microbiome Data (16s rRNA , WholeMetaGenome)]

Feature(Microbiome) x Sample Matrix

Feature/Sample	Bacteria species 1	Bacteria species 2	s__Eubacterium_l ramulus	s__Gemmiger variabilis_B
Sample 1	0.001	0.002	3.298	6.124
Sample 2	0.000	0.004	9.972	17.231
Sample 3	0.005	0.000	12.203	4.245

- Feature Filtering : Cutoff (≤ 0.001)

Relative Abundance (Compositional Data) :

- A relative ratio where the sum of the values of **each sample is constant**

High-dimensional Sparse Matrix :


- The number of features is much greater than the number of samples and the value of most cells is **very high at 0**

- Not define $\log(0)$ -> need Normalization (ex. +1 Pseudo counts)


Right-skewed Distribution :

- Some microorganisms account for a high abundance. (Dominant species)

5-Fold : Train – Valid – Test




What is AUC (Area Under the Curve)?



The probability that a randomly selected positive sample will receive a higher prediction score than a randomly selected negative sample.


All models in this paper evaluate models that classify each disease and health group using binary classification and present the median

Why the Lasso model for method setup?



Model	Metaphor	Algorithm
Ridge	Deduct a small amount from all feature scores	L2: Shrinks coefficients toward zero (no elimination)
Lasso	Set low-contribution feature scores to zero	L1: Forces some coefficients to zero → removes variables
Random Forest	Comprehensive scoring via repeated varied tests	Hundreds of decision trees → majority vote

What is RandomForest?



Model	Metaphor	Algorithm
Ridge	Deduct a small amount from all feature scores	L2: Shrinks coefficients toward zero (no elimination)
Lasso	Set low-contribution feature scores to zero	L1: Forces some coefficients to zero → removes variables
Random Forest	Comprehensive scoring via repeated varied tests	Hundreds of decision trees → majority vote

Rescaling / Normalization / Confounder


Rescaling vs Normalization — 같은 데이터, 다른 변환



	Confounder
Target	Biological & clinical variables (age, sex, BMI, etc.)
Cause	Biological/clinical variables influence the outcome variable
When to Apply	At study design stage, before model training

Figure 2-a,b

Workflow [Figure 2.]



Internal : Evaluated Valid Set

External : Evaluated Test Set

Rank : Lining


Log (CLR) : Log
CLR : Central Log Ratio

Std : z-score

Unit : vector norm

Figure 2-c

Workflow [Figure 2.]



Filtered (False / 0.001)
Rescale (False / Min-Max)
Normalized (False / rank.std)
Confunder (False / SIAMCAT)

Confunder did not have a positive effect on AUC in all cases.

Figure 3-a.b

Comparison of contributions for each stage




Figure 4-a

Comparison of Batch Correction Methods





Figure 4-b

R2 Score of Batch Correction Methods

Explaining variance after batch effect removal



- Best Option : Sva (ComBat)
- Worst Option : Limma (removeBatchEffect)



A high R^2 (close to 1.0) means the feature is heavily contaminated by batch
A low R^2 (close to 0) means batch explains very little of the expression variance, indicating either a clean dataset or that batch correction has been successfully applied.

Figure 4-c

Comparison of Two representative machine learning models

C

Algorithm comparison



RandomForest : Filterd – Normalized
Ridge : Filtered – Scaled – Normalized

Figure 4-d

Comparison of All machine learning models





Figure 4-e

Result

e



Thank You

Q & A

Q&A

1.

약물을 복용했을 때, 그 자체로 장내 미생물 구성을 바꿔놓는 교란요인이 있는 것으로 알고 있습니다. 고령 환자나 만성질환이 있는 환자들의 경우 여러 약물을 동시에 복용하기도 하는데, 이 논문에서 제안한 워크플로우가 질병으로 인한 장내 미생물 변화와 복용 중이 다양한 약물로 인한 미생물 변화를 분리해서 분석할 수 있는지 궁금합니다.

2.

임상데이터를 받으면, 환자가 그동안 복용한 약과 복용기간이 잘 적혀있는 데이터를 받아서 분석하시는건지, 아니면 환자의 질병 유무와 장내 미생물에 관한 정보만 받는건지도 궁금합니다.

Q&A

1.

이 논문을 읽으며 궁금했던 점은,

논문의 저자는 confounder correction 과정에서 disease-associated biological signal까지 같이 제거되어 AUC가 감소되어 모델의 성능이 저하되었다 라고 해석하는 것 같았습니다.

그런데 모델이 disease biology가 아니라 국가 차이나 병원의 차이와 같은 cohort 간의 차이와 같은 confounding signal을 일부 학습하고 있었고 confounder correction 이후에

이러한 가짜 signal이 제거되면서 biological-relevant한 disease-associated biological signal만 남게 되었을 가능성은 없을지도 궁금합니다.

Q&A

1.

논문에서는 microbiome 기반 machine learning model이 다양한 질병 진단에 활용될 수 있음을 보여주었지만, discussion에서 gut microbiome이 식이, 약물, 지역, 생활습관 등 질병 외 요인의 영향을 크게 받는다고도 설명하고 있습니다. 또한 이러한 confounding factor를 보정하면 질병군과 건강군 간의 차이가 줄어들어 AUC가 낮아질 수 있다고 언급하고 있습니다. 저는 이 점이 microbiome을 diseased sample과 healthy sample을 구별하는 질병 특이적 biomarker로 사용하기에는 다소 한계가 있을 수도 있다는 의미로 느껴졌습니다. 그렇다면 이러한 한계를 보완하고, 실제 임상에서 질병 biomarker로 활용하기 위해서는 어떤 추가 검증이나 실험, 혹은 기술적인 접근이 필요할지 궁금합니다.

Q&A

1.

여러가지 ML 모델을 비교해서 보여주셨는데, 중간에 비교한 모델 중 NN이 보여서, 질문 자체가 애매모호할 수 있다 생각하지만, ML 모델 선정 범위가 어떻게 되는지, 즉 다른 DL은 포함시키지 않은 거 같은데 NN은 왜 포함시켰는지 궁금했습니다.

제가 예전에 질병 분류 모델에 대해 알아보고 특히 DL 기반 질병 분류 모델에 관해 찾아본 적이 있어서 (<https://github.com/minoh0201/DeepMicro> 그 중 하나인데 혹시 관심 있으시다면), 자원이 허락된다면, NN 외에도 다른 DL 모델의 성능 또한 같이 비교해보면 재밌지 않았을까라는 생각이 들었습니다.

2.

AUC 기준으로 모델들의 성능을 비교하신 거 같은데, 수치만 보면 큰 차이가 나는 것 같지는 않아서, CPU 시간, ram 사용량 등도 같이 고려하는 게 어떨까라는 생각이 들었습니다.

3. 이건 제 개인 연구 주제와도 어느 정도 연결될 수도 있는데, 본 논문에서 사용한 sample 개수가 1만 개가 넘어가서 dataset이 크다고 볼 수 있을 거 같은데, 이 결과를 크기가 작은 dataset에는 그대로 적용 못할 것 같다고 생각했습니다. Small cohort에서 model 성능을 비교한 연구가 있는지, 어떤 모델이 적절할 것 같은지 생각이 궁금합니다.

Q&A

1.

Hello,

In Machine learning algorithm comparison section, the paper shows that Ridge Regression (doesn't do feature selection) outperformed Lasso.

Does this show that the model relies on the rare or low abundance microbes which are usually filtered out as noise and it carries critical diagnostic signatures that the model relies on? and what is the risk of overfitting when we execute this pipeline in actual unseen hospital cohorts?
